ChatGPT

2021–2026 年音訊神經網路式 AEC 演算法深度研究報告

執行摘要

聲學回聲消除（Acoustic Echo Cancellation, AEC）在全雙工語音通訊、智慧喇叭、會議系統與免持通話中，仍是最影響使用者主觀品質的核心前處理之一。近五年（2021–2026）研究趨勢高度受到 **Microsoft AEC Challenge** 系列資料集、盲測與主觀測評框架驅動，研究焦點從「端到端深度模型能否做 AEC」轉向「**在嚴格低延遲與即時推論限制下**，如何同時兼顧主觀品質、雙講（double-talk）穩健性、延遲漂移（misalignment）、非線性回聲、裝置泛化與可部署性」。 [1]

在方法面，2021–2022 年主流可歸納為三條路線：
一是以 **FCRN/CRN 等時頻域深度網路**直接估計近端語音或回聲（含複數網路與頻率–時間 LSTM），並在競賽資料上用 MOS/DMOS 驗證；二是 **Hybrid（線性 AEC + NN 後濾波/RES）**，將線性濾波器處理「可線性解釋」的回聲，再以 NN 抑制殘餘（含非線性）回聲與噪聲；三是把傳統自適應濾波器「可微分化」嵌入深度學習框架，使網路學到步階/對齊/參考訊號估計等控制量，提升在回聲路徑連續變化時的穩健性。 [2]

2022–2024 年的主旋律是「**對齊（alignment）內化**」與「**任務整合與產品化**」。代表性工作把過去外掛的延遲估計（TDE；例如 GCC-PHAT）改由注意力/交叉注意力在模型內部完成，可直接處理未對齊輸入並簡化 pipeline；同時出現可落地的 **joint AEC+NS+DR** 單模型（DeepVQE）與以 ASR 目標（WER）驅動的 AEC 訓練策略，明確把「通訊品質」與「下游辨識」綁定。 [3]

2024–2026 年則快速分化成兩個方向：
（1）**極低複雜度/邊緣部署**：例如 Align-ULCNet、EchoFree、E2E-AEC 等，關注參數量、MACs、延遲、RTF 與泛化；（2）**生成式/擴散式（diffusion）AEC**：嘗試用「隨機再生（stochastic regeneration）」框架解決傳統遮罩/映射模型的上限，但必須面對 diffusion 多步推論帶來的延遲與計算量，於是又衍生出「每幀一次 score」或「更少步數」的折衷設計。 [4]

在評測面，競賽推動了更貼近主觀感受與大規模可重現的指標與框架：P.808（眾包主觀測評）與 **AECMOS**（以人類主觀評分訓練的客觀預測模型）逐漸取代只看 ERLE 或 PESQ 的「單指標」觀點；並且把 **語音辨識字詞正確率（WAcc）**納入挑戰分數，逼迫模型在抑制回聲的同時，不能破壞可辨識性。 [5]

問題定義與方法分類

AEC 的信號模型與核心目標

在單通道（單喇叭、單麥克風）最常用的模型中，麥克風訊號可寫為

$$y(n) = s(n) + d(n) + v(n),$$

其中 $s(n)$ 為近端語音、$v(n)$ 為噪聲，而回聲 $d(n)$ 由遠端參考訊號 $x(n)$ 經回聲路徑（常以 RIR/LEM 系統表徵）產生。此形式在多篇 2021–2024 代表作中被反覆採用作為問題定義。 [6]

傳統線性 AEC 多以可適應 FIR 濾波器估計回聲並做減法：

$$e(n) = y(n) - \hat{d}(n),$$

再由後濾波器做殘餘回聲抑制（RES）與降噪。Hybrid NN AEC 基本上延續此結構，只是把「後濾波器/殘餘抑制」交給深度模型，或把自適應濾波器層可微分化以便端到端訓練。 [7]

研究路線分類（2021–2026 的實務聚類）

下列分類對應到文獻中「系統 pipeline 的切分方式」，也是規劃實驗時最關鍵的設計決策：

Hybrid：線性 AEC + NN 後濾波/RES（主流可部署路線）
優點是線性部分對近端失真通常較小、可控性高；NN 專注處理非線性殘餘回聲與噪聲，容易在嚴格延遲限制下取得較佳折衷。代表：multi-input FCRN 研究、NWPU 競賽系統、EchoFree、Align-ULCNet 等。 [8]

端到端時頻域模型（遮罩/複數映射/直接估計乾淨語音）
透過 CRN/FCRN、複數網路與頻率–時間循環結構同時建模相位與長時序，常用於同時處理 AEC+NS，並在競賽資料上以 MOS/DMOS 驗證。代表：F-T-LSTM 複數網路、Y^2-Net、端到端複數 D3Net。 [9]

對齊內化（alignment-aware / alignment-free）
把以往外掛的 TDE（或假設固定延遲）改由交叉注意力/串流注意力做「軟對齊」，目標是提升非同步、延遲漂移、裝置差異情境下的穩健性並簡化 pipeline。代表：Microsoft built-in cross-attention alignment、SCA。 [10]

joint 任務整合（AEC+NS+DR；甚至加入 ASR/WAcc 目標）
把回聲、噪聲、混響一併處理，對產品更有吸引力，但訓練與失真控制更困難。代表：DeepVQE；以及以 ASR Loss/WER 驅動的 waveform-domain AEC。 [11]

生成式/擴散式 AEC（diffusion）
以擴散模型的逐步反推（reverse diffusion）思路做「回聲消除後的訊號再生」，在品質上有潛力，但要解決多步推論帶來的高延遲，於是出現「每幀一次 score」與「更少步數」的加速設計。代表：FADI-AEC、FSD。 [12]

即時性約束的硬規格（由 AEC Challenge 明確化）

ICASSP 2023 AEC Challenge 對提交模型明確要求：**RTF ≤ 0.5（單執行緒 i5 2.4GHz）**、**演算法延遲 + 緩衝延遲 ≤ 20ms**、推論不得使用未來資訊（因果限制）。這使得「非因果 U-Net 大模型」在該基準下通常不具可比性，也解釋為何 2024–2026 開始大量出現輕量與低延遲設計。 [13]

架構對照圖（管線級）

```
flowchart LR
  subgraph A["Hybrid（線性 AEC + NN 後濾波）"]
    x1[Far-end x] --> tde1[TDE/對齊(可選)]
    y1[Mic y] --> tde1
    tde1 --> laec[線性自適應濾波器(LAEC)]
    laec --> e[殘差/誤差信號 e 或回聲估計 d^]
    e --> nn1[NN 後濾波/RES/NS]
    nn1 --> out1[輸出 ŝ]
  end
```

```
  subgraph B["端到端（遮罩/映射/直接估計）"]
    x2[Far-end x] --> nn2[CRN/FCRN/複數網路]
    y2[Mic y] --> nn2
    nn2 --> out2[輸出 ŝ 或 mask]
  end

  subgraph C["對齊內化（注意力/交叉注意力）"]
    x3[Far-end x] --> align[Cross-attn 對齊模組]
    y3[Mic y] --> align
    align --> nn3[串流/端到端 AEC 模型]
    nn3 --> out3[輸出 ŝ]
  end

  subgraph D["擴散式（Diffusion）"]
    x4[Far-end x] --> ngen[Noise/擾動生成(含 far-end 引導)]
    y4[Mic y] --> ngen
    ngen --> score[Score 模型(每幀一次/少步數)]
    score --> out4[輸出 ŝ]
  end
```

文獻回顧：挑戰基準、FCRN 與複數時頻模型的成形

競賽基準與可重現評測框架的奠基

ICASSP 2021 AEC Challenge 的核心貢獻不只在資料量，而在於把「真實錄音泛化落差」與「傳統客觀指標（如 ERLE、PESQ）與主觀不一致」明確化，並釋出大型真實+合成資料、盲測與線上主觀測評框架。 14

其 **baseline** 明確是一個可在公開資料上重建的深度模型：以麥克風與遠端訊號的 **log power spectral features** 為輸入（STFT：20ms frame、10ms hop、320 點 DFT），用兩層 GRU + 全連接 sigmoid 產生抑制遮罩，遮罩乘在麥克風幅度譜上，最後用麥克風相位做 iSTFT；以幅度譜 MSE 訓練，Adam、learning rate 0.0003、在無噪合成資料訓練 500 epochs。 15

INTERSPEECH 2021 AEC Challenge 延續同一套資料精神，並總結參賽方法從「純深度」到「Hybrid」與「DSP」；結果顯示深度與 Hybrid 顯著勝過純 DSP，但仍有改進空間。 16

ICASSP 2022 AEC Challenge 把 fullband、WAcc 與模型複雜度納入更強約束，並給出挑戰分數的明確公式，把（FEST、NEST、DTecho、DTother）與 WAcc 等權重平均，逼迫研究者在「抑制回聲」與「不破壞可辨識/可聽品質」間取得平衡。 17

AEC in a NetShell：把 FCRN 系統化並檢驗「訓練目標」與「融合拓樸」的代價

Jan Franzen, Ernst Seidel, Tim Fingscheidt. “AEC in a NetShell: On Target and Topology Choices for FCRN Acoustic Echo Cancellation.” (arXiv/ICASSP 2021). 18

問題陳述：早期端到端 DNN AEC 雖有很強的回聲抑制，但常伴隨「近端語音品質明顯受損」。本文的核心是把已在降噪領域成熟的 FCRN encoder–decoder 拿來做 AEC，並系統性分析「**輸出目標到底要學乾淨語音、還是**

要學回聲估計再相減」以及「reference 與 mic 訊號在 encoder 的何處融合（early/middle/late fusion）」、「skip connection 放置」等設計對品質/抑制的取捨。 18

模型架構（要點）：在 STFT/DFT 域輸入 $X_\ell(k)$（reference）與 $Y_\ell(k)$（mic），採用 FCRN encoder–decoder + bottleneck ConvLSTM；並提供多種 fusion、skip 變體。論文同時討論三種訓練 target：
1) 直接回歸 $E_\ell(k) = S_\ell(k) + N_\ell(k)$（只做 AEC，不做降噪）
2) 直接回歸 $E_\ell(k) = S_\ell(k)$（做 AEC+降噪）
3) 回歸回聲 $\hat{D}_\ell(k)$，再做 $\hat{E}_\ell(k) = Y_\ell(k) - \hat{D}_\ell(k)$（貼近傳統 AEC 概念）並用頻域 MSE。 18

關鍵前處理/特徵：16kHz、frame length 512、shift 256、sqrt Hann、512-point DFT，將複數譜拆成實部/虛部 two-channel，並 zero-pad 頻率維度到 $M = 260$。 18

訓練資料與增強：用 TIMIT 作 far/near speech，QUT 作訓練噪聲，NOISEX-92 作測試噪聲；回聲由 loudspeaker nonlinearity + IR 卷積生成，IR 由 image method 合成且 T_{60} 在訓練/測試做分離；SER、SNR 以離散集合隨機抽樣，且包含 ∞ 用來確保模型能處理無回聲/無噪情境；測試端用 VCTK 未見 speaker/utterance。 18

評估與結論（方向性）：本文最重要的可操作價值在於「把 AEC 深度模型的設計空間拆解成可控旋鈕」，並直接指出：**output target 的選擇、fusion 與 skip 的位置**會讓「回聲抑制」與「近端失真」在同一模型容量下出現顯著 trade-off，研究者應該先決定產品需求（可懂度優先 vs 失真容忍度 vs 噪聲處理）再選 target。 18
可重現資源：原文未在 PDF 中明確提供官方開源 repo（若有則未指定）。此細節依來源標記為未明。 18

Y^2-Net：用「兩階段」把 AEC 與後濾波拆開以降低近端失真

Ernst Seidel, Jan Franzen, Maximilian Strake, Tim Fingscheidt. "Y^2-Net FCRN for Acoustic Echo and Noise Suppression." (arXiv 2021). 19

問題陳述：把 AEC、RES、降噪塞進單一網路容易造成近端品質下降，原因之一是缺少對「回聲估計」的明確 supervision。 19

模型架構：兩個串接的 Y-Net（皆為 FCRN encoder–decoder + ConvLSTM）。第一階段（AEC）輸入 (X_ℓ, Y_ℓ) 回歸回聲估計 $\hat{D}_\ell(k)$，再做減法得到中間訊號 $E_\ell(k)$；第二階段（PF）輸入 $(E_\ell, \hat{D}_\ell)$ 估計複數遮罩 $M_\ell(k)$，並用 amplitude compression 形成輸出：

$$\hat{S}_\ell(k) = E_\ell(k) \cdot \tanh(|M_\ell(k)|) \cdot \frac{M_\ell(k)}{|M_\ell(k)|}.$$

19

即時性設計（延遲）：在 16kHz 下使用 NT=424 samples frame、50% shift，並以此計算演算法延遲 $T_1 = T + T_s = 39.75\text{ms} \leq 40\text{ms}$。 19

結果摘要：在 INTERSPEECH 2021 AEC Challenge 的盲測雙講情境，以主辦方提供之 DECMOS 指標平均較 baseline 高 0.46（主觀測試多數接近 baseline）。 19
可重現資源：原文未在 PDF 中明確提供官方 repo（未指定）。 19

複數網路 + F–T LSTM：把相位與頻帶關聯顯式建模

Shimin Zhang, Yuxiang Kong, Shubo Lv, Yanxin Hu, Lei Xie. “F-T-LSTM based Complex Network for Joint Acoustic Echo Cancellation and Speech Enhancement.” (INTERSPEECH 2021). [20]

問題陳述：AEC 在噪聲、混響、非線性失真下更困難；傳統線性 AEC + 後濾波在殘餘回聲抑制上效率不足。[20]

架構：複數 encoder–decoder（複數 Conv2d / Transposed-Conv2d）+ 複數 LSTM，並加入 F-T-LSTM：先在頻率軸做雙向 F-LSTM 建模跨頻帶關聯，再掃時間軸做 T-LSTM；以此提高回聲抑制並降低近端失真。[20]

訓練與資料增強（相對完整、可直接復刻）：
近端語音用 LibriSpeech train-clean-100；噪聲用 DNS 約 80h；遠端語音與回聲資料混用 challenge 合成集與真實 far-end single-talk 錄音（文中提到約 37h）；SNR ∈ [5,20] dB、SER ∈ [−10,13] dB；訓練中以機率將 far-end/echo 置零來模擬 near-end single talk、將噪聲置零模擬乾淨情境；加入 0–100ms 隨機延遲以模擬對齊失誤；並以 image method 生成 10k RIR 做近端混響增強。[20]

損失：文中強調使用「modified/segmented SI-SNR」提升 AEC+NS 表現（細節以原文為準；若需逐式推導應回到全文）。[20]

結果摘要：模型約 1.4M 參數，在 MOS 上較 AEC challenge baseline 高 0.27。[20]
可重現資源：文中未在 PDF 明確提供官方訓練程式碼（未指定），但提供示例音檔頁面（第三方）不屬主要來源，因此此處不作為復刻依據。[20]

多喇叭/多麥克風：深度方法避免 stereophonic AEC 的非唯一性困境

Hao Zhang, DeLiang Wang. “Multi-Channel and Multi-Microphone Acoustic Echo Cancellation Using a Deep Learning Based Approach.” (arXiv 2021；亦對應 INTERSPEECH 2021 版本). [21]

問題陳述：傳統多喇叭（stereo）AEC 存在 non-uniqueness problem（喇叭訊號相關性高導致路徑難唯一辨識、收斂差），多麥克風 AEC 與 beamforming 結合亦常遇到收斂/耦合困難。本文主張「直接估計近端語音」的深度方法可內生避免該問題。[21]

模型：比較 BLSTM 與 CRN（含 encoder–LSTM–decoder 的常見 CRN 結構）在 MCAEC/MMAEC；並探討與深度 beamforming 串接（先做 AEC 再做 beamforming 或相反）之效果。[21]

評估指標與部分結果（可用於跨論文數值比較）：本文報告 ERLE 與 PESQ；例如在 MMAEC（double-talk、背景噪聲、SER 3.5dB、SNR 10dB、線性系統）條件下，相較 JONLMS（ERLE 約 6.9dB），深度模型可達 ERLE 數十 dB 等級並可提升 PESQ；且與 beamforming 結合可再提升 PESQ。[21]
同時在包含非線性失真（$\eta^2 = 0.1, 0.5$）條件下仍能維持高 ERLE/PESQ，顯示對非線性具一定泛化。[21]

可重現資源：arXiv 版本未在 PDF 中指明官方 repo（未指定）。[21]

文獻回顧：Hybrid 強化、可微分 DSP 與競賽分數驅動的訓練策略

Deep Adaptive AEC：把 NLMS 變成可微分層，讓網路學「步階」與「參考」控制量

Hao Zhang, Srivatsan Kandadai, Harsha Rao, Minje Kim, Tarun Pruthi, Trausti Kristjansson. “Deep Adaptive AEC: Hybrid of Deep Learning and Adaptive Acoustic Echo Cancellation.” (ICASSP 2022). [22]

核心概念：把傳統線性自適應濾波（文中示例用 NLMS）實作成「無可訓參數的可微分層」，使梯度能穿過 adaptive layer，讓前面的 DNN 學到（a）更好的 playback reference 的估計，以及（b）隨時間變化的 learning factor/step-size 控制，從而在訓練階段對「回聲路徑連續變化、低 SER/SNR」更穩健。 [22]

形式化：文中以 STFT 域混合模型 $Y_{k,m} = D_{k,m} + S_{k,m} + N_{k,m}$ 開始並給出整體管線示意圖（DNN → Linear AEC → Loss/Gradients）。 [22]

可部署性含意：這類「DDSP 化」的混合架構，通常比純端到端大模型更容易在計算量與穩健性上取得平衡，且提供工程上更清楚的除錯界面（例如 step-size 飽和、追蹤失效）。此點在論文動機與結論段落中被明確強調。 [22]
訓練細節：PDF 可見更多實驗設定與比較，但在目前可取得片段中未完整列出所有超參數（依來源標記為未完全指定）。 [22]

Multi-input FCRN：分析「後濾波輸入到底要餵什麼」比換 backbone 更關鍵

Jan Franzen, Tim Fingscheidt. “Deep Residual Echo Suppression and Noise Reduction: A Multi-Input FCRN Approach in a Hybrid Speech Enhancement System.” (arXiv 2021；ICASSP 2022 對應版本). [23]

問題陳述：Hybrid 系統的第二段（RES/NR）常被當成「把 reference、mic、(可選) error 丟進去」即可，但其實輸入組合會深刻影響「回聲抑制、降噪、近端失真」三者的 trade-off。 [23]

方法：以 frequency-domain adaptive Kalman filter AEC 作第一段、FCRN 作第二段，窮舉/比較最多四種輸入信號組合，並檢驗 direct estimation vs complex mask 等設計。 [23]

關鍵發現（高度可操作）：作者指出一個「反直覺但可復驗」的結論：**不建議把 loudspeaker reference 直接餵給第二段 RES/NR**；更好的輸入組合是「AEC 後的 enhanced 信號」+「原 mic」+「echo estimate」，並宣稱相較既有方式可帶來 >0.2 PESQ 的提升。 [23]
可重現資源：PDF 未明確提供官方 repo（未指定）。 [23]

ICASSP 2022 Challenge 冠軍級 hybrid 設計：echo-aware loss + VAD 多任務

Shimin Zhang, Ziteng Wang, Jiayao Sun, Yihui Fu, Biao Tian, Qiang Fu, Lei Xie. “Multi-Task Deep Residual Echo Suppression with Echo-aware Loss.” (arXiv/ICASSP 2022). [24]

系統定位：典型 Hybrid：線性 AEC 負責線性回聲，NN post-filter 抑制非線性殘餘回聲（含噪聲）。 [24]

架構：post-filter 使用 gated convolutional F-T-LSTM（GFTNN）並加入 VAD 輔助任務（MTL），以降低 over-suppression 導致的近端失真並提升 WAcc；同時採用 echo-aware loss，使 MSE 在每個 TF-bin 依 SER 加權，強化回聲占優 bins 的抑制。 [24]

全頻帶處理策略：為控制複雜度，使用 3-band FIR filter-bank + DCT modulation，把 48k fullband 分解後只處理 16k wideband，再以平均增益控制恢復高頻能量（文中給出增益計算式）。 24

排名/數值結果（挑戰官方指標）：在 ICASSP 2022 AEC Challenge：WAcc 0.817（第 1）、MOS 4.502（第 3）、final score 0.864（第 3）。 24

可重現資源：論文性質為競賽系統描述，PDF 未明確列出官方開源 repo（未指定）。 24

端到端複數 D3Net：用極小參數量挑戰 hybrid pipeline

Karn N. Watcharasupat, Thi Ngoc Tho Nguyen, Woon-Seng Gan, Shengkui Zhao, Bin Ma. “End-to-End Complex-Valued Multidilated Convolutional Neural Network for Joint Acoustic Echo Cancellation and Noise Suppression.” (arXiv 2021；ICASSP 2022). 25

動機：傳統兩段式（線性 AEC + neural RES）需要收斂並對環境變化敏感，且可能引入不必要延遲；作者主張 neural module 本身有能力同時抑制線性與非線性回聲，因此提出 end-to-end 複數網路。 25

關鍵設計：以 pseudocomplex D3Net（densely-connected multi-dilated DenseNet）作為 building block，利用 multi-resolution receptive field **不必 pooling** 仍可擴大感受野；模型僅 354K 參數；並提出 dual-mask 做 joint echo+noise suppression。 25

形式化：文中給出包含非線性失真的更一般信號模型 $p[t] = s[t] + n[t] + f(q)[t]$ 與 TF 域對應式，明確把 residual echo 視為非線性項 $g(Q)$。 25

訓練細節/超參數：在目前可取得片段中，完整訓練資料與超參數未在摘要段落完全展開；若要復刻需回到 PDF 的實驗章節逐項擷取（依來源標記為未完全指定）。 25

文獻回顧：對齊內化、任務整合與更嚴格的即時推論門檻

2023 Challenge：更低延遲 + AECMOS 強化，且「小模型反而更強」的反直覺觀察

Ross Cutler 等. “ICASSP 2023 Acoustic Echo Cancellation Challenge.” (arXiv 2023). 26

規格升級：ICASSP 2023 將延遲要求從先前規格進一步壓到 **20ms**，並強制 RTF ≤ 0.5、因果推論。 13

AECMOS 可用性（關聯性）：本文提供 AECMOS 與人類主觀評分的相關係數表（PCC/SRCC/Tau-b），例如 far-end single talk echo DMOS 的 PCC=0.99、double talk echo DMOS PCC=0.99、near-end SIG MOS PCC=0.85 等，顯示 AECMOS 在競賽模型排序上可作為高相關的 proxy。 27

趨勢觀察：在該挑戰，作者指出「模型大小與整體分數」呈負相關（PCC=-0.54，**小模型傾向勝過大模型**），同時 RTF 與整體分數正相關（PCC=0.67，較高複雜度傾向更好）。這兩句看似矛盾，但常見解釋是：在固定延遲與實作限制下，大模型更可能因工程與穩健性問題未達最佳折衷，而某些精心設計的小模型（特別是 hybrid/輕量 joint 模型）反而更能「把有效計算用在刀口上」。 27

built-in cross-attention alignment：把 delay estimation 從外掛模組變成可學習、可泛化的一部分

Evgenii Indenbom, Nicolae-Cătălin Ristea, Ando Saabas, Tanel Parnamaa, Jegor Guzvin, Ross Cutler. “Deep Model with Built-in Cross-Attention Alignment for Acoustic Echo Cancellation.” (arXiv 2022). [28]

問題陳述：mic 與 far-end 參考訊號的同步（alignment）是好 AEC 的必要條件，但傳統以 cross-correlation 為基礎的 TDE 模組是外掛 block，存在已知限制；作者提出把 alignment 以 cross-attention 方式內建到模型中，直接處理未對齊輸入。 [28]

貢獻與結果（摘要級）：在 AEC Challenge 真實錄音中，對困難 delay estimation 情境可顯著改善；同時宣稱在低複雜度 AEC 上達到 SOTA，並已部署於 Microsoft Teams（規模以論文描述為準）。 [29]

可重現資源：PDF 未明確提供官方 repo 或 checkpoint（未指定）。 [28]

SCA：Streaming cross-attention alignment 的端到端化版本

Yang Liu, Yangyang Shi, Yun Li, Kaustubh Kalgaonkar, Sriram Srinivasan, Xin Lei. “SCA: Streaming Cross-Attention Alignment for Echo Cancellation.” (arXiv 2022；文中提及 ICASSP 2023). [30]

核心概念：提出具串流 cross-attention alignment 的端到端 AEC，能在無外部對齊模組下處理未對齊輸入，並簡化 time-variant echo path 的 pipeline。 [30]

評測：在 ICASSP2022 與 INTERSPEECH2021 的 Microsoft deep echo cancellation challenge evaluation dataset 上，宣稱優於部分 hybrid 與 end-to-end baseline。 [31]
訓練細節：在目前可見摘要段落中未完整列出（未指定）。 [30]

DeepVQE：joint AEC+NS+DR 的產品導向單模型

Evgenii Indenbom, Nicolae-Cătălin Ristea, Ando Saabas, Tanel Parnamaa, Jegor Guzvin, Ross Cutler. “DeepVQE: Real Time Deep Voice Quality Enhancement for Joint Acoustic Echo Cancellation, Noise Suppression and Dereverberation.” (INTERSPEECH 2023). [32]

問題陳述：AEC、噪聲與混響在實務上相互影響；將三者串接成多段 DSP/NN pipeline 會造成工程複雜且不易部署，因此提出單一 joint 模型。 [32]

架構要點（摘要/貢獻段落）：提出 real-time cross-attention deep model（Residual CNN + RNN），並提到 alignment block、residual block、sub-pixel convolution、CCM 等設計元素，以同時兼顧回聲與降噪品質。 [33]

結果摘要：在 ICASSP 2023 AEC Challenge 與 DNS Challenge 的 non-personalized test sets 取得 SOTA，並宣稱已在 Microsoft Teams 平台成功測試。 [33]

可重現資源：論文 PDF 未提供官方訓練 repo；網路上存在第三方重現 repo，但非 primary source，因此此處僅將「官方未指定」標記為未明。 [32]

ASR 驅動的 waveform-domain AEC：把「聽起來好」改成「辨識率高」的最佳化目標

Sankaran Panchapagesan, Arun Narayanan, Turaj Zakizadeh Shabestary, Shuai Shao, Nathan Howard, Alex Park, James Walker, Alexander Gruenstein. “A Conformer-based Waveform-domain Neural Acoustic Echo Canceller Optimized for ASR Accuracy.” (arXiv/INTERSPEECH 2022). [34]

主張：在智慧喇叭等情境，AEC 的核心 KPI 可能是 **WER/WAcc**，而非僅語音增強指標；因此透過 **SI-SNR + ASR loss** 的 multi-task 訓練，讓輸出更利於預訓練 ASR encoder。 [35]

結果摘要（論文摘要）：在 rerecorded test set 上，串接 linear AEC + waveform neural AEC 可相對 linear AEC 單獨使用帶來 56–59% WER reduction；且 1.6M 參數的 waveform-domain 模型可優於更大的 6.5M logmel-domain 模型。 [36]

訓練細節：在目前可見片段中未完整列出資料規模與完整超參數（未指定）。 [34]

文獻回顧：輕量化、生成式方法、以及 2026 的端到端串流化

以「回聲路徑」作輔助標籤：Deep Echo Path Modeling

Fei Zhao, Chenggang Zhang, Shulin He, Jinjiang Liu, Xueliang Zhang. “Deep Echo Path Modeling for Acoustic Echo Cancellation.” (INTERSPEECH 2024). [37]

核心想法：端到端 AEC 常被批評泛化不足；本文改以「先在 single-talk（無近端）估計 echo path」並在時頻域預測 echo path，再把預測的 echo paths 當成 double-talk 訓練時的 auxiliary labels，等於把「回聲路徑估計」顯式加回 supervision，試圖提升 unseen acoustic scenarios 的泛化。 [37]

實驗結論（摘要級）：作者表示相較強 baselines 有更好表現與泛化能力。 [37]
訓練細節：摘要段落未列出完整資料集與超參數（未指定）。 [37]

以能量縮放改變學習難度：SDAEC（Signal Decoupling）

Fei Zhao, Jinjiang Liu, Xueliang Zhang. “SDAEC: Signal Decoupling for Advancing Acoustic Echo Cancellation.” (INTERSPEECH 2024). [38]

洞察：在低 SER 情境下，reference 與 mic 的能量差使深度模型難以隱式學到 echo path；因此先建模兩者能量得到 scaling factor，把 reference 做縮放後再餵入後續 AEC 網路，降低學習難度。 [38]

效果：作者宣稱可提升多個 baseline 模型的 AEC 表現。 [38]
訓練細節：未在摘要段落完整列出（未指定）。 [38]

傳統濾波理論回歸：Attention-Enhanced Short-Time Wiener Solution

Fei Zhao, Xueliang Zhang. “Attention-Enhanced Short-Time Wiener Solution for Acoustic Echo Cancellation.” (arXiv 2024). [39]

主張：近年 deep AEC 偏重架構堆疊，較少把傳統濾波理論的「可解釋解」直接整合進模型；本文提出把 **short-term Wiener solution**（有限長度、因果輸入版本）作為基礎訊號處理元件，再用 attention 在 double-talk 下做特徵篩選，並把 Wiener 解的結果與既有 AEC NN（文中稱對 ICCRN 的增強）結合。 [39]

關鍵推導（摘要可見片段）：文中在 T-F domain 重寫 Wiener 相關式（如式 (8) 類型的正規方程），把 X, Y, H（far-end、mic、濾波解/傳遞）關係顯式化，作為後續模型輸入的一部分。 [40]

可重現資源：作者在 arXiv 摘要頁明確給出官方程式碼 repo（見後述連結區塊）。 [41]

低複雜度 Hybrid AENR：Align-ULCNet

Shrishti Saha Shetu, Naveen Kumar Desiraju, Wolfgang Mack, Emanuel A. P. Habets. "Align-ULCNet: Towards Low-Complexity and Robust Acoustic Echo and Noise Reduction." (arXiv 2024). [42]

貢獻：以 Kalman filter + DNN hybrid 做 AENR，並提出兩個對部署友善的設計：
1) latent space 的 time alignment（降低對輸入同步假設的敏感度）
2) channel-wise sampling-based feature reorientation（在低複雜度下提升穩健性與泛化）
並在非線性、低通、較大 delay 等 adverse scenario 顯示更好的 generalization。 [42]

可重現資源：arXiv PDF 未指明官方訓練 repo（未指定）；但存在作者團隊展示頁（非主要來源），此處不作 primary 依據。 [42]

擴散式 AEC：FADI-AEC 與 FSD

Yang Liu 等. "FADI-AEC: Fast Score Based Diffusion Model Guided by Far-end Signal for Acoustic Echo Cancellation." (arXiv 2024). [43]
提出 DI-AEC（diffusion-based stochastic regeneration）與加速版 FADI-AEC，核心是把 score model 的執行壓到「每幀一次」，並用 far-end 引導的 noise generation，使 diffusion 兼顧效率與準確；在 ICASSP2023 challenge evaluation dataset 上宣稱優於部分端到端與其他 diffusion 方法。 [43]

Yang Liu 等. "FSD: Acoustic Echo Cancellation with Fewer Step Diffusion." (OpenReview/NeurIPS 2024 Workshop). [44]
FSD 延續上述想法，但更強調「減少 diffusion 步數」與「利用上一幀輸出狀態」來達到 real-time。論文表格直接給出 latency 與客觀指標：傳統 diffusion 版本延遲可達 325ms，而 FSD 可降至 9.14ms（文中說符合典型 10ms real-time 要求），同時維持高 ERLE/PESQ。 [44]

> 重要提醒：diffusion 相關論文的 latency 定義與測試平台可能與 AEC Challenge 的 RTF/latency 規格不同；跨論文比較必須先對齊「延遲定義、幀長、是否含 buffering、硬體」等條件。 [45]

超輕量化：EchoFree（Bark-scale 特徵 + SSL 兩階段最佳化）

Xingchen Li, Boyi Kang, Ziqian Wang, Zihan Zhang, Mingshuai Liu, Zhonghua Fu, Lei Xie. "EchoFree: Towards Ultra Lightweight and Efficient Neural Acoustic Echo Cancellation." (arXiv 2025). [46]

框架：結合 linear filtering 與 neural post-filter；neural post-filter 在 Bark-scale 頻譜特徵上運作；並提出利用 self-supervised learning（SSL）模型的兩階段最佳化策略，以提升小模型品質。 [47]

效率宣稱：僅 278K 參數、30 MMACs；在 ICASSP 2023 AEC Challenge 盲測上，宣稱可在低複雜度下達到接近 DeepVQE-S 的表現。 [46]

可重現資源：文中提供 audio examples（論文註腳）；是否提供完整訓練程式碼需依原文後續段落確認（摘要片段未示），故此處標記未完全指定。 [46]

2026：E2E-AEC 的串流端到端化（progressive learning + knowledge transfer + VAD masking）

Yiheng Jiang, Biao Tian, Haoxu Wang, Shengkui Zhao, Bin Ma, Daren Chen, Xiangang Li. “E2E-AEC: Implementing an End-to-End Neural Network Learning Approach for Acoustic Echo Cancellation.” (arXiv 2026). [48]

核心策略：

- progressive learning：逐步提升回聲抑制能力
- knowledge transfer：以先訓練的 LAEC-based 模型初始化（把 hybrid 知識轉移到 E2E）
- attention alignment loss：對注意力權重加 loss 以促進精準時間對齊
- VAD prediction + masking：在無近端語音時遮罩輸出以改善品質
  並宣稱在公開資料集（含 AEC Challenge datasets）上顯著提升 AECMOS 與 ERLE。 [48]

數值片段：文中提到某設定下 VAD 分支的位置影響 ERLE，並給出 ERLE=78.69dB 的示例結果（需在完整表格中核對其測試條件）。 [48]

可重現資源：arXiv PDF 未明確提供官方 repo（未指定）。 [48]

綜合比較與趨勢：資料集、SOTA 走向、開放問題與部署建議

常用資料集與評測基準的「事實標準」

Microsoft AEC-Challenge（真實 + 合成）
資料庫與 baseline、評測工具由官方 GitHub 提供，並持續被 2021–2026 多數工作引用作為可比基準。 [49]
ICASSP 2023 challenge 的 real dataset 描述包含多種 single-talk/double-talk 與 echo path change 的情境設計，並且納入個人化 track（提供 near-end enrollment clip）。 [26]

主觀測評：P.808 + 第三方聆聽測試設計
競賽明確採用 online subjective framework（P.808 toolkit 的延伸）評估回聲與其他失真。 [50]

客觀 proxy：AECMOS
AECMOS 以人類主觀評分訓練，可用於 stack-rank AEC 方法；ICASSP 2023 challenge 給出其與人類評分的高相關係數作為證據。 [51]

傳統客觀指標仍有價值但需搭配情境
ERLE、PESQ 仍常用於合成或可取得 clean/echo reference 的情境（如多通道 AEC、學術模擬），但在真實噪聲與混響下與主觀的關係有限，這也是競賽把 MOS/DMOS 與 AECMOS 納入核心指標的原因。 [52]

代表性演算法比較表（研究規劃用）

> 註：**Year** 為發表/預印年份；Causal/Real-time 欄位以論文或 challenge 規格敘述為準；未明者標記 Unspecified。

Year	Work	Model type	Input / Feature	Causal / Stream	Supervision	Eval dataset	Metrics
2021	ICASSP 2021 AEC Challenge baseline [15]	Masking (GRU)	log power STFT feats; mask on	Stream (frame-based)	supervised (MSE mag)	AEC-Challenge	MOS/ DMOS (challenge)
2021	AEC in a NetShell [18]	FCRN+ConvLSTM	DFT complex (Re/Im), M=260	Stream	supervised (MSE; multiple targets)	TIMIT/QUT/ NOISEX+sim IR	(paper reports)
2021	Y^2-Net [19]	2-stage FCRN (AEC + PF)	DFT complex, mask compression	Stream (≈40ms)	supervised (echo + mask)	AEC Challenge eval	DECMOS, MOS
2021	F-T-LSTM complex network [20]	Complex encoder-decoder + F/T-LSTM	STFT complex, phase-aware	Real-time oriented	supervised (segmented SI-SNR)	AEC Challenge(+DNS)	MOS, (others)
2021	Multi-channel & multi-mic AEC [21]	BLSTM / CRN	STFT mag/ phase (paper)	Stream	supervised	simulated rooms + nonlinearities	ERLE, PESQ
2022	Deep Adaptive AEC [22]	Differentiable NLMS + DNN	STFT-domain; NN predicts control	Stream	supervised (end-to-end)	(paper setups)	(paper reports)
2022	Multi-input FCRN RES/ NR [23]	Hybrid Kalman AEC + FCRN	mic / AEC out / echo est	Stream	supervised	(paper setups)	PESQ (+trade-offs)
2022	Echo-aware MTL post-filter [24]	Hybrid + GFTNN + VAD	subband (48k→16k) + DEY	Stream	supervised + MTL	ICASSP 2022 AEC Challenge	MOS, WAcc, score
2022	End-to-end complex D3Net [25]	Complex D3Net (354K)	complex TF masks	Stream	supervised	real+synthetic	energy/ perceptual proxies
2022	Built-in cross-attn alignment [28]	Alignment-aware (cross-attn)	mic + far-end	Stream	supervised	AEC Challenge real	(paper reports)
2022	SCA [30]	Streaming cross-attn alignment	mic + far-end	Stream	supervised	MS challenge eval	(paper reports)

Year	Work	Model type	Input / Feature	Causal / Stream	Supervision	Eval dataset	Metrics
2023	DeepVQE [32]	joint AEC+NS+DR	mic + far-end; alignment block	Real-time	supervised	AEC/DNS Challenge 2023	SOTA claim
2024	Deep echo path modeling [37]	Echo-path prediction + auxiliary labels	TF echo path	Stream	supervised (aux labels)	(paper setups)	(paper reports)
2024	SDAEC signal decoupling [38]	energy scaling preproc + AEC net	scaled far-end + mic	Stream	supervised	(paper setups)	(paper reports)
2024	Align-ULCNet [42]	Kalman + low-cost DNN	AENR features	Stream	supervised	(paper setups)	echo/noise reduction
2024	ASTWS-AEC [39]	Wiener theory + attention + ICCRN	TF-domain + Wiener component	Stream	supervised	baselines comparisons	(paper reports)
2024	FADI-AEC [43]	diffusion (fast score / frame)	far-end guided noise	Stream-oriented	supervised	ICASSP 2023 eval	(paper reports)
2024	FSD [44]	diffusion (fewer step)	far-end guided sampling	Stream	supervised	ICASSP 2023 eval	ERLE, PESQ, latency
2025	EchoFree [46]	ultra-light hybrid	Bark-scale + post-filter	Stream	SSL 2-stage + supervised	ICASSP 2023 blind	(AECMOS etc)
2026	E2E-AEC [48]	streaming E2E + PL + VAD	mic + far-end + attention	Stream	supervised + transfer	AEC Challenge datasets	AECMOS, ERLE

數值對照表：跨論文可直接引用的指標片段

多麥克風 AEC（ERLE/PESQ；Zhang & Wang 2021）

下表摘錄論文 Table 2/3 的部分數值（皆為該論文特定房間/噪聲/失真設定；在不同論文間不可直接當作 SOTA 排名，只能作為「方法類型」的量級參考）。[21]

Setting (paper-defined)	Method	ERLE (dB)	PESQ
MMAEC, DT+noise, SER=3.5dB, SNR=10dB, linear	JONLMS	~6.9	~2.43–2.48
同上	BLSTM (ŝ)	~62–67	~2.57–2.74
同上	BLSTM + beamforming (ŝ_bf)	~60–67	~2.68–2.87
同上	CRN (ŝ)	~26–34	~2.66–2.94
同上	CRN + beamforming (ŝ_bf)	~28–37	~2.75–2.99

擴散式 AEC 的「延遲–品質」典型取捨（FSD 2024）

FSD 論文在同一張表中提供 latency 與 ERLE/PESQ，清楚呈現 diffusion 多步推論的延遲代價與其加速版本的折衷。 44

Model family	Params (M)	Latency (ms)	ERLE FEST (dB)	PESQ NEST
CRN (small)	3.6	4.04	67.67	4.41
CRN (large)	7.8	8.93	82.45	4.50
Diffusion (multi-step)	6.9	325.00	92.51–92.83	4.87–4.91
FSD (fewer step)	6.9	9.14	85.80–89.75	4.79–4.85

圖表：代表性方法的延遲比較（僅作量級示意）

```
xychart-beta
title "代表性方法推論延遲量級（不同論文定義；僅示意）"
x-axis ["CRN(s)","CRN(l)","Diffusion","FSD","CDEC","Y2-Net"]
y-axis "Latency (ms)" 0 --> 350
bar [4.04, 8.93, 325.00, 9.14, 32.00, 39.75]
```

上圖中：CRN/Diffusion/FSD 數值來源於 FSD 論文；CDEC（Cross-Domain Echo-Controller）延遲 32ms 來自其 submission 描述；Y2-Net 的延遲 39.75ms 來自其幀設計推導。 54

時間軸：2021–2026 里程碑

```
timeline
title 2021–2026 NN-AEC 研究里程碑（與代表作）
  2021 : 公開 AEC Challenge 資料/主觀測評框架
       : FCRN 系統化設計空間（AEC in a NetShell）
       : 複數網路與頻率-時間建模（F-T-LSTM）
```

```
      : 兩階段拆分 AEC 與後濾波（Y^2-Net）
 2022 : Fullband + WAcc 驅動的競賽目標
      : 可微分自適應濾波（Deep Adaptive AEC）
      : 極小參數端到端複數網路（Complex D3Net）
      : 對齊內化（cross-attention alignment / SCA）
 2023 : 20ms 低延遲與 RTF 限制成為硬門檻
      : joint AEC+NS+DR 單模型走向產品化（DeepVQE）
 2024 : 以 echo-path/能量縮放改善泛化（Deep echo path, SDAEC）
      : diffusion AEC 興起與加速（FADI-AEC, FSD）
      : 傳統濾波理論回歸（ASTWS-AEC）
 2025 : 超輕量化與 SSL 兩階段訓練（EchoFree）
 2026 : 串流端到端 + transfer + VAD masking（E2E-AEC）
```

時間軸所列作品與規格演進，分別對應 challenge 論文與各代表作。 55

未解挑戰與建議研究方向（面向你的實驗規劃）

對齊與延遲漂移仍是第一級痛點
多篇 2022–2024 工作顯示「把 alignment 內化」能顯著提高困難延遲情境的表現，但注意力機制如何在串流/低延遲下維持穩定，仍是設計關鍵（例如需要限制注意力範圍、或以 loss 約束注意力峰值）。 56

泛化：端到端模型容易過度抑制近端語音
Echo-path modeling 與 signal decoupling 兩條路線本質上是在「把可解釋的中間變量」加回 supervision 或 preproc，以降低網路在低 SER 時的學習難度並提升 unseen scenario 泛化。你若要做研究型改良，這兩種思路都比單純堆 backbone 更容易做出可解釋的增益。 57

低複雜度不等於低效果：競賽觀察反而偏向小模型
ICASSP 2023 challenge 的統計觀察指出小模型往往更好。這通常意味著：在嚴格延遲限制下，「把計算用在 alignment、Hybrid conditioning、或針對性特徵（如 Bark/子頻帶）」比盲目增加參數更有效。 58

生成式方法（diffusion）目前更像研究前沿而非工程默認
FADI-AEC/FSD 顯示 diffusion 在品質上有吸引力，但延遲與計算仍是關鍵瓶頸；即使 FSD 宣稱可達 9.14ms，仍須在你實際 target hardware 上用統一的 RTF/latency 定義重測，並與 challenge 規格一致化才有工程意義。 45

建議的研究方向（可直接形成實驗矩陣）
1) **Hybrid + alignment-aware**：把線性 AEC 作為「特徵/conditioning」而非直接濾波（競賽中多次出現類似觀點），並把對齊內化成小型 attention block；觀察 AECMOS/WAcc 與近端 SIG MOS 之取捨。 59
2) **輕量頻帶特徵與知識蒸餾/SSL**：EchoFree 的 Bark-scale + SSL 兩階段策略顯示，在低資源部署上「特徵設計 + 訓練策略」可能比 backbone 更重要。 46
3) **可微分 DSP 元件**：Deep Adaptive AEC 類型的方法很適合做「小模型可控性」研究：你可以把 step-size、leakage、double-talk control 等控制量改成可學習頭，並以 AECMOS/主觀 proxy 作為選模依據。 60
4) **多通道/空間資訊**：若你的產品場景有多麥克風，Zhang & Wang 類工作顯示深度 AEC 與 beamforming 的結合能顯著提升；後續研究（例如 DOA 融合）亦可追蹤，但需確保評測資料與目標應用一致。 61

部署考量清單（把論文變成可上線系統時最常踩雷的點）

延遲與幀設計：挑戰明確把延遲壓到 20ms 量級；若你採 STFT 系統，frame/hop、look-ahead、overlap-add 都會直接決定 buffering latency。 62
RTF 與 CPU 單執行緒瓶頸：AEC Challenge 用單執行緒 i5 2.4GHz 類規格衡量 RTF；研究時至少要在同等級

CPU 以單執行緒量測，否則 latency/RTF 報告不可比。 [26]
量化與運算子支援：低複雜度模型往往需要 INT8/ONNX/TFLite 等部署；但複數運算、ConvLSTM、attention、diffusion sampling 可能在推論框架中難以高效落地（這也是近年偏向簡化對齊模組、或以 latent-space 對齊降低運算需求的原因之一）。 [63]
品質監控：AECMOS 的高相關性使其可作為 CI/回歸測試的主指標之一；但仍建議保留少量主觀聽測集作 sanity check，避免模型「對 AECMOS 過擬合」。 [51]

臺灣論文（臺灣博碩士論文系統）蒐集狀態與可得資訊

在本次檢索中，臺灣博碩士論文知識加值系統（NDLTD）部分論文頁面觸發圖片驗證碼（CAPTCHA），導致無法穩定自動抓取全文內容。因此，本節僅能引用「可在搜尋結果摘要中取得」的中繼資訊；若你需要逐篇論文的完整公式、資料集、訓練細節與實驗表格，建議以人工方式進入 NDLTD 下載全文，或提供 PDF 讓我可用 PDF 分析流程做逐段萃取。 [64]

目前在可取得摘要資訊中，有一篇明確以深度 AEC 為核心且落在 2021–2026 視窗內的題目：

- **〈結合交叉注意力與改進損失函數的 DTLN-AEC 模型〉**（元智大學；發表年度在摘要中標示為 2025；NDLTD ID: 113YZU00442044）。摘要指出以 DTLN-AEC 為基礎，強化非線性回聲與混合情境處理，並強調低計算負載/推理速度/輕量化以利即時部署。可得資訊僅止於摘要；架構細節、公式推導、資料集/超參數、以及實驗表格在目前來源中未完整揭示，故標記為未指定。 [65]

重要連結彙整（資料集、評測、開源資源）

依規範，連結以純文字 code block 形式提供（不在正文中直接放 URL）。

```
Microsoft AEC Challenge (datasets + baselines + AECMOS pointers)
https://github.com/microsoft/AEC-Challenge

ICASSP 2023 AEC Challenge portal (rules / description)
https://www.microsoft.com/en-us/research/academic-program/acoustic-echo-
cancellation-challenge-icassp-2023/

Attention-Enhanced Short-Time Wiener Solution for AEC (ASTWS-AEC) official
code (as stated by paper)
https://github.com/ZhaoF-i/ASTWS-AEC
```

以上連結分別對應官方資料集/競賽頁與論文宣稱之官方程式碼。 [66]

---

[1] [14] [15] [50] [52] [55] https://www.microsoft.com/en-us/research/wp-content/uploads/2021/06/0000151.pdf
https://www.microsoft.com/en-us/research/wp-content/uploads/2021/06/0000151.pdf

[2] [18] https://arxiv.org/pdf/2103.09007
https://arxiv.org/pdf/2103.09007

3 10 28 29 56 https://arxiv.org/pdf/2208.11308
https://arxiv.org/pdf/2208.11308

4 42 63 https://arxiv.org/pdf/2410.13620
https://arxiv.org/pdf/2410.13620

5 13 26 27 51 58 62 https://arxiv.org/pdf/2309.12553
https://arxiv.org/pdf/2309.12553

6 22 60 https://minjekim.com/wp-content/uploads/icassp2022_hzhang.pdf
https://minjekim.com/wp-content/uploads/icassp2022_hzhang.pdf

7 https://www.isca-archive.org/interspeech_2021/pfeifenberger21_interspeech.pdf
https://www.isca-archive.org/interspeech_2021/pfeifenberger21_interspeech.pdf

8 23 https://arxiv.org/pdf/2108.03051
https://arxiv.org/pdf/2108.03051

9 20 https://www.isca-archive.org/interspeech_2021/zhang21ia_interspeech.pdf
https://www.isca-archive.org/interspeech_2021/zhang21ia_interspeech.pdf

11 32 33 https://www.isca-archive.org/interspeech_2023/ristea23_interspeech.pdf
https://www.isca-archive.org/interspeech_2023/ristea23_interspeech.pdf

12 43 https://arxiv.org/pdf/2401.04283
https://arxiv.org/pdf/2401.04283

16 https://www.isca-archive.org/interspeech_2021/cutler21_interspeech.pdf
https://www.isca-archive.org/interspeech_2021/cutler21_interspeech.pdf

17 59 https://www.microsoft.com/en-us/research/wp-content/uploads/2022/07/0009107.pdf
https://www.microsoft.com/en-us/research/wp-content/uploads/2022/07/0009107.pdf

19 https://arxiv.org/pdf/2103.17189
https://arxiv.org/pdf/2103.17189

21 61 https://arxiv.org/pdf/2103.02552
https://arxiv.org/pdf/2103.02552

24 https://arxiv.org/pdf/2202.06850
https://arxiv.org/pdf/2202.06850

25 https://arxiv.org/pdf/2110.00745
https://arxiv.org/pdf/2110.00745

30 31 https://arxiv.org/pdf/2211.00589
https://arxiv.org/pdf/2211.00589

34 35 https://arxiv.org/pdf/2205.03481
https://arxiv.org/pdf/2205.03481

36 https://arxiv.org/abs/2205.03481
https://arxiv.org/abs/2205.03481

37 57 https://www.isca-archive.org/interspeech_2024/zhao24_interspeech.pdf
https://www.isca-archive.org/interspeech_2024/zhao24_interspeech.pdf

38 https://www.isca-archive.org/interspeech_2024/zhao24b_interspeech.pdf
https://www.isca-archive.org/interspeech_2024/zhao24b_interspeech.pdf

39 40 https://arxiv.org/pdf/2412.18851
https://arxiv.org/pdf/2412.18851

41 https://arxiv.org/abs/2412.18851
https://arxiv.org/abs/2412.18851

44 45 54 https://openreview.net/pdf?id=J2T6MwthQE
https://openreview.net/pdf?id=J2T6MwthQE

46 https://arxiv.org/pdf/2508.06271
https://arxiv.org/pdf/2508.06271

47 https://arxiv.org/abs/2508.06271
https://arxiv.org/abs/2508.06271

48 https://arxiv.org/pdf/2601.16774
https://arxiv.org/pdf/2601.16774

49 53 66 https://github.com/microsoft/aec-challenge
https://github.com/microsoft/aec-challenge

64 65 https://ndltd.ncl.edu.tw/cgi-bin/gs32/gsweb.cgi/login?o=dnclcdr&s=id%3D%22113YZU00442044%22.&searchmode=basic
https://ndltd.ncl.edu.tw/cgi-bin/gs32/gsweb.cgi/login?o=dnclcdr&s=id%3D%22113YZU00442044%22.&searchmode=basic